

¿Cómo se relaciona la ubicación geográfica de una vivienda en Medellín con su precio de venta?

Kevin Arley Parra Henao
Universidad Nacional de Colombia, sede Medellín
Curso de Análisis Geoespacial

Resumen—En este trabajo se analiza cómo se relaciona la ubicación geográfica de una vivienda en Medellín con su precio de venta. Se parte de un conjunto de datos de la plataforma Kaggle que contiene información sobre inmuebles en Colombia, como el número de habitaciones, dormitorios y baños, su ubicación y su precio de venta, entre otros datos. El precio está expresado en pesos colombianos. Para aplicar los modelos estudiados, se realizó la limpieza, el filtrado, el procesamiento y la normalización de los datos. Asimismo, se utilizó el logaritmo natural del precio para estabilizar los análisis. Los inmuebles se representaron como puntos marcados y se estudiaron mediante técnicas de análisis geoespacial. También se utilizaron métodos de aprendizaje automático, como Random Forest, para comparar los resultados con los de los modelos espaciales. El precio logarítmico presentó dependencia espacial positiva y significativa (I de Moran de 0.5898 con diez vecinos, $p = 0.001$). El modelo SAR-Lag confirmó una relación positiva con los precios vecinos ($\rho = 0.5496$), mientras que el MGWR y el modelo jerárquico mostraron que el efecto de los atributos y el nivel base del precio cambian entre zonas y barrios. En la evaluación, Random Forest fue el modelo con mayor capacidad predictiva ($R^2 = 0.7756$ y RMSE de 0.3485 en escala logarítmica); entre los modelos espaciales interpretables, SAR-Lag fue el mejor ($R^2 = 0.5997$). Por tanto, la ubicación se relaciona con el precio por el contexto barrial, la semejanza entre viviendas cercanas y la variación territorial de las relaciones.

I. INTRODUCCIÓN

El precio de una vivienda no depende únicamente de sus habitaciones, dormitorios o baños. Dos inmuebles con características parecidas pueden tener precios diferentes por estar ubicados en barrios distintos. La accesibilidad, la seguridad, los servicios cercanos, la calidad del entorno y la valoración histórica de cada sector forman parte de esa diferencia. Además, los anuncios próximos suelen compartir condiciones de mercado y, por tanto, sus precios pueden parecerse.

Este comportamiento plantea dos conceptos principales. La *dependencia espacial* aparece cuando el precio de una vivienda se relaciona con los precios de las viviendas cercanas. La *heterogeneidad espacial* ocurre cuando una misma característica no tiene la misma relación con el precio en toda la ciudad. Por ejemplo, un baño adicional puede estar asociado con un cambio mayor de precio en una zona que en otra.

Los materiales del curso presentan herramientas para estudiar estas dos dimensiones, desde patrones de puntos y autocorrelación hasta modelos locales, jerárquicos y procesos gaussianos [1], [2]. Siguiendo ese enfoque, este proyecto responde dos preguntas: ¿cómo se relaciona la ubicación geográfica de una vivienda en Medellín con su precio?, y ¿cómo la ubicación y

la cercanía de inmuebles vecinos ayudan a explicar y predecir su precio de venta?

El objetivo es describir el patrón territorial del precio, medir su dependencia espacial, evaluar si las relaciones cambian entre zonas y comparar métodos de predicción espacial. No se busca establecer causalidad. Los resultados indican asociaciones: muestran dónde aparecen los patrones y cuánto ayudan a explicar o predecir el precio.

II. DATOS Y METODOLOGÍA

II-A. Datos y representación espacial

Los datos se descargaron directamente desde Kaggle a partir del conjunto *Colombia Housing Properties Price* [3]. Después de la descarga se realizó dentro del proyecto la limpieza y el procesamiento necesarios para construir el conjunto de análisis. La unidad de observación es un anuncio inmobiliario y la variable original `price` corresponde al precio de venta anunciado en pesos colombianos, no a su logaritmo. Primero se seleccionaron las columnas útiles, se filtró la ciudad Medellín y se conservaron únicamente operaciones de venta. También se eliminaron columnas constantes o sin información para Medellín, como ciudad, localidad y barrio de los niveles 15 y 16, además del título del anuncio.

De los 119 394 anuncios de venta identificados en Medellín, se eliminaron aquellos sin coordenadas o sin precio. Para reducir la influencia de valores extremos se conservaron los precios entre los percentiles 1 y 99. El conjunto resultante contiene 35 814 anuncios, con precios entre 82 millones y 4,200 millones de pesos y una mediana de 420 millones. Se dividió una sola vez en 25 069 observaciones de entrenamiento (70 %) y 10 745 de prueba (30 %), con semilla 42.

Los valores faltantes numéricos se imputaron con la mediana calculada en entrenamiento y luego se estandarizaron con media cero y desviación estándar uno. Los faltantes categóricos se imputaron con la categoría más frecuente; barrio y tipo de propiedad se codificaron mediante variables indicadoras. Todo el preprocesamiento se ajustó solo con entrenamiento y se reutilizó en prueba para evitar fuga de información. Las variables de superficie tenían muy pocos datos disponibles y, aunque se usaron en los modelos generales de aprendizaje automático, no se incluyeron en los modelos espaciales explicativos.

Las variables empleadas incluyen precio, longitud, latitud, barrio, tipo de propiedad, habitaciones, dormitorios y baños. El precio original se conservó para describir resultados en

pesos. Debido a su asimetría, para la etapa espacial se creó una variable adicional:

$$y_i = \log(\text{precio}_i).$$

El logaritmo reduce la influencia de viviendas muy costosas y facilita la comparación de cambios relativos; no reemplaza ni modifica el dato de precio original. Esta transformación y su uso en el análisis de precios espaciales siguen el tratamiento presentado en el material del curso [1].

Los anuncios se convirtieron en puntos y se proyectaron en MAGNA-SIRGAS / Origen-Nacional (EPSG:9377), cuyas unidades son metros. Como la etiqueta Medellín del conjunto original contenía algunas coordenadas fuera del municipio, el análisis espacial conservó únicamente los puntos ubicados dentro de sus límites. La unión espacial con 252 polígonos del material del curso asignó 22 857 puntos de entrenamiento a 226 barrios con al menos un anuncio. GWR, MGWR y los procesos continuos utilizaron muestras de estas geometrías válidas para controlar el costo computacional.

El código utilizado para el procesamiento, los modelos y la generación de las figuras está disponible en el repositorio del proyecto [4].

II-B. Patrón de puntos y agrupamiento

Cada anuncio se trató como un punto con una marca de precio. Se calcularon el centro medio, el centro ponderado por `log_price`, una elipse de desviación estándar y la envolvente convexa. La superficie kernel normalizada se definió como:

$$\hat{m}(s) = \frac{\sum_i K_h(s - s_i) y_i}{\sum_i K_h(s - s_i)},$$

con ancho de banda de 1 km. La normalización evita confundir una zona con muchos anuncios con una zona de precios altos. La formulación del suavizado kernel se basa en el capítulo de patrones de puntos del libro del curso [2].

K-means se ajustó solamente con coordenadas proyectadas y estandarizadas. Se probaron entre dos y seis grupos. Silhouette mide qué tan compactos y separados están los grupos, mientras el método del codo identifica cuándo aumentar el número de clusters deja de reducir de manera importante la inercia.

II-C. Dependencia espacial

Para los puntos se construyeron matrices de los vecinos más cercanos (KNN) con 5, 10 y 20 vecinos. En este caso, k indica cuántos vecinos se consideran alrededor de cada vivienda y no corresponde al número de grupos de K-means. Moran global mide si los valores cercanos tienden a parecerse. Un valor positivo y significativo indica agrupación de valores similares. Moran local o LISA identifica dónde ocurre el patrón:

- Alto-Alto: precio alto rodeado por precios altos.
- Bajo-Bajo: precio bajo rodeado por precios bajos.
- Alto-Bajo y Bajo-Alto: observaciones que contrastan con su entorno.

Para los barrios se utilizó una matriz Queen: dos barrios son vecinos si comparten un borde o un vértice. Se calcularon

Moran y LISA sobre la mediana barrial de `log_price`, usando 999 permutaciones.

OLS se empleó como modelo global de referencia:

$$\mathbf{y} = \mathbf{X}\beta + \varepsilon.$$

La notación de OLS y de los modelos espaciales siguientes se basa en los contenidos de correlación y regresión espacial del libro y del material del curso [2], [1]. Luego se ajustaron SEM y SAR. SEM representa dependencia en factores espaciales no incluidos:

$$\mathbf{u} = \lambda \mathbf{W}\mathbf{u} + \varepsilon.$$

SAR incorpora el precio de las viviendas vecinas:

$$\mathbf{y} = \rho \mathbf{W}\mathbf{y} + \mathbf{X}\beta + \varepsilon.$$

Como referencia predictiva se ajustaron Random Forest y XGBoost con las variables numéricas y categóricas procesadas. Se utilizaron principalmente como modelos de contraste no espacial, para comparar el desempeño predictivo de los modelos espaciales con algoritmos de otra familia. Sus hiperparámetros se eligieron mediante validación cruzada dentro del entrenamiento y la evaluación final se realizó sobre las mismas 10 745 observaciones de prueba. Aunque permiten establecer cuánto puede predecirse, no describen directamente la dependencia o la heterogeneidad espacial ni entregan un parámetro interpretable como ρ en SAR-Lag.

II-D. Heterogeneidad y regímenes espaciales

GWR (*Geographically Weighted Regression*) estima coeficientes alrededor de cada punto y usa un ancho de banda común. MGWR (*Multiscale Geographically Weighted Regression*) permite un ancho diferente para cada variable:

$$y_i = \beta_0(s_i) + \sum_{k=1}^p \beta_k(s_i) x_{ik} + \varepsilon_i.$$

Esta formulación corresponde al desarrollo de GWR y MGWR presentado en el libro del curso [2].

Se seleccionaron 1 890 puntos distribuidos dentro de Medellín. Los predictores fueron habitaciones, dormitorios y baños estandarizados. El ancho se seleccionó mediante AICc, que compara ajuste y complejidad y penaliza parámetros innecesarios. También se evaluaron significancia local, número de condición y Moran residual.

Para representar barrios como regímenes se compararon OLS, un *Random Intercept Model* y un modelo con intercepto y pendiente aleatoria de baños. El ICC se calculó como:

$$\text{ICC} = \frac{\sigma_{\text{barrio}}^2}{\sigma_{\text{barrio}}^2 + \sigma_{\text{residual}}^2}.$$

Este valor indica qué parte de la variación restante corresponde a diferencias entre barrios. La definición del ICC y la estructura jerárquica siguen el capítulo de modelos jerárquicos del libro [2].

II-E. Interpolación y validación espacial

Se construyeron 38 bloques espaciales de aproximadamente 2 km: 1 646 puntos quedaron para entrenamiento y 244 para prueba. Ningún bloque de prueba apareció en entrenamiento, por lo que la evaluación representa la predicción de zonas completas no observadas.

Kriging ordinario predice mediante valores cercanos y un variograma. Se compararon modelos esférico, exponencial y gaussiano, con un máximo de 80 vecinos. Regresión-Kriging primero estimó la tendencia con habitaciones, dormitorios y baños mediante Ridge y después interpoló los residuos.

El proceso gaussiano utilizó un kernel Matérn con ruido blanco:

$$k(s_i, s_j) = \sigma_f^2 k_{\text{Matérn } 3/2}(s_i, s_j) + \sigma_n^2 \delta_{ij}.$$

La representación mediante funciones de covarianza y ruido se basa en los capítulos de Kriging y procesos gaussianos del libro y en el material del curso [2], [1]. La media posterior es la predicción y la desviación estándar posterior mide incertidumbre. Los métodos se compararon con R^2 , MAE, RMSE y Moran residual.

III. RESULTADOS

III-A. Patrón espacial y barrios

La Fig. 1 presenta cada vivienda en su posición y utiliza el precio logarítmico como marca. La mayor concentración de anuncios aparece en el corredor central, el occidente y el sur de Medellín. También se observan valores altos en el suroriente, especialmente en El Poblado. El logaritmo permite distinguir mejor el patrón sin dejar que unos pocos precios extremos controlen toda la escala de color. Los espacios con pocos puntos representan menor cobertura de anuncios y no necesariamente ausencia de viviendas.

El centro medio se ubicó en Tenche y el centro ponderado por precio en Trinidad. La distancia entre ambos fue de 65.02 m. El pequeño desplazamiento indica que los anuncios costosos del suroriente no cambian mucho el centro general, porque la oferta también se distribuye por el centro, occidente y norte. La elipse presentó semiejes de 3.38 km y 1.81 km, con orientación de 105.33 grados, coherente con la forma alargada del valle.

La superficie kernel varió aproximadamente entre 19.00 y 20.64 en escala logarítmica, equivalentes a valores cercanos a 178 y 922 millones de pesos. Sus máximos se concentran hacia El Poblado y representan promedios locales altos, no solo mayor cantidad de anuncios.

Una zona con muchos puntos no necesariamente tiene el mayor precio local, porque la superficie divide la suma ponderada del precio por la densidad de anuncios. Por ello, los máximos representan entornos donde los anuncios cercanos son, en promedio, más costosos. Las zonas sin soporte suficiente no se estiman y no deben interpretarse como precios bajos.

K-means seleccionó tres clusters con Silhouette de 0.520. El cluster 0 agrupó principalmente sectores centrales y del norte, como La Candelaria y Boston, con mediana de 250 millones. El cluster 1 cubrió buena parte del occidente, incluidos Laureles,




Figura 1. Viviendas como puntos marcados por el precio logarítmico. El mapa conserva las coordenadas EPSG:9377, la escala gráfica, el norte y los límites barriales.

Los Conquistadores y Belén, con 340 millones. El cluster 2 reunió principalmente El Poblado, con barrios como El Tesoro, San Lucas, Los Balsos y Castropol, y alcanzó 690 millones. El precio no definió los grupos; las diferencias aparecieron después de agrupar solamente por ubicación.

La Fig. 3 muestra por qué se eligieron tres grupos: allí aparece el mayor Silhouette y el cambio de la inercia empieza a ser menor. La Fig. 4 muestra su distribución dentro de Medellín. La diferencia entre medianas indica que la geometría por sí sola recupera zonas con mercados distintos. Sin embargo, los clusters no reemplazan los límites administrativos ni prueban que la ubicación sea la causa del precio. Son regiones estadísticas definidas por cercanía a centroides.

Las coropletas de la Fig. 5 separan el nivel de precio y la cantidad de oferta observada. El mapa izquierdo confirma medianas mayores en el sur y suroriente, mientras gran parte del norte presenta valores menores. El derecho muestra que la densidad de anuncios es desigual y se concentra en algunos barrios del centro, occidente y sur. Por ello, un barrio oscuro en el mapa de densidad no es necesariamente más costoso; indica más anuncios por unidad de área. Las áreas blancas no tienen información suficiente en la muestra analizada.

III-B. Dependencia espacial global y local

Sí existe dependencia espacial. El análisis de sensibilidad de la matriz KNN produjo valores de Moran de 0.6254 para $k = 5$, 0.5898 para $k = 10$ y 0.5553 para $k = 20$; en los tres casos, $p = 0.001$. Todos los resultados son positivos y




Figura 2. Centrografía del patrón de anuncios. La cruz es el centro medio, la estrella es el centro ponderado por precio, la elipse resume dispersión y la línea roja muestra la envolvente convexa.

significativos: las viviendas cercanas tienden a presentar precios similares y el patrón no se explica por azar. Moran disminuye al incluir más vecinos porque la relación es más fuerte en el entorno inmediato y se suaviza al ampliar el área analizada. Sin embargo, incluso con veinte vecinos la dependencia permanece clara. Estos valores de k pertenecen al análisis KNN de Moran y son independientes de los tres clusters elegidos mediante K-means.

LISA puntual clasificó 23.81 % de las viviendas como Alto-Alto y 24.44 % como Bajo-Bajo. Los casos Bajo-Alto representaron 3.23 % y los Alto-Bajo 2.09 %. A escala barrial, Moran fue 0.4752 ($p = 0.001$). Se identificaron 29 barrios Alto-Alto, con mediana conjunta de 690 millones, y 37 Bajo-Bajo, con mediana de 165 millones.

En la Fig. 6, Alto-Alto representa viviendas costosas rodeadas por otras costosas y Bajo-Bajo viviendas de menor precio dentro de entornos similares. Estos dos grupos dominan el resultado y muestran continuidad local del mercado. Alto-Bajo y Bajo-Alto son contrastes puntuales con sus vecinos; su menor frecuencia indica que son casos menos comunes. Los puntos no significativos no presentan evidencia suficiente para asignarles un patrón local.

La matriz Queen tuvo 4.86 vecinos por barrio, dos componentes conectados y ninguna isla. El componente principal incluyó 224 barrios; el segundo estuvo formado por María

Cuadro I
COMPARACIÓN COMÚN SOBRE PRECIO LOGARÍTMICO EN PRUEBA

Modelo	R^2	RMSE	Moran residual
OLS	0.5828	0.4752	0.1926
SEM	0.5649	0.4853	0.2437
SAR-Lag	0.5997	0.4655	0.1753
Random Forest	0.7756	0.3485	0.0293
XGBoost	0.5944	0.4686	0.0790

Cuadro II
COMPARACIÓN DE HETEROGENEIDAD SOBRE 1 890 PUNTOS

Modelo	R^2 aj.	AICc	RMSE	Moran
OLS	0.3758	—	0.6129	0.2722
GWR	0.5985	2837.88	0.4738	0.0132
MGWR	0.6102	2773.17	0.4678	-0.0347

Cano-Carambolas y Carpinelo, conectados entre sí pero no con los barrios observados del componente principal.

III-C. Modelos globales y comparación predictiva

OLS obtuvo $R^2 = 0.5870$ y RMSE de 0.4745 en entrenamiento. Sin embargo, sus residuos conservaron Moran de 0.2461 ($p = 0.001$). Por tanto, los atributos incluidos no explicaron toda la estructura territorial.

SEM estimó $\lambda = 0.7351$ ($p < 0.001$). El valor alto indica que factores territoriales no incluidos comparten un patrón entre viviendas vecinas. Después de filtrar esa estructura, el error presentó Moran de -0.0013 y $p = 0.243$, sin evidencia de dependencia restante.

SAR-Lag estimó $\rho = 0.5496$ ($p < 0.001$). Esto significa que el precio vecino aporta información positiva al explicar el precio de una vivienda. En prueba, fue el mejor modelo espacial global, con $R^2 = 0.5997$ y RMSE de 0.4655. Su Moran residual fue 0.1753, por lo que todavía quedó estructura sin explicar.

Random Forest obtuvo el mejor desempeño general y dejó la menor autocorrelación residual. En consecuencia, fue el mejor modelo para predecir el precio entre los evaluados. Sin embargo, SAR-Lag es el modelo que responde de forma más directa a la pregunta espacial: su parámetro ρ cuantifica la relación positiva entre el precio de una vivienda y los precios de sus vecinas. Esta diferencia entre precisión e interpretación evita asignar ambos objetivos a un único modelo.

III-D. Heterogeneidad espacial

MGWR obtuvo el mejor equilibrio entre ajuste y complejidad. Sus anchos de banda fueron 64 vecinos para el intercepto, 1 015 para habitaciones, 364 para dormitorios y 149 para baños. El ancho grande de habitaciones indica una relación amplia y estable; los anchos menores del intercepto y baños permiten cambios más locales.

Baños fue positivo y significativo en 83.54 % de los puntos, habitaciones en 54.07 % y dormitorios en 5.03 %. El coeficiente local de baños varió aproximadamente entre 0.154 y 0.747. Por tanto, sí hay heterogeneidad: la relación es




Figura 3. Selección del número de clusters. El panel izquierdo muestra el método del codo y el derecho el coeficiente Silhouette para valores de k entre 2 y 6.




Figura 4. Agrupamiento espacial K-means con $k = 3$. Los grupos se construyen únicamente con las coordenadas; la leyenda presenta el precio mediano calculado después del agrupamiento.

positiva, pero su intensidad cambia según la zona. Ningún punto superó el número de condición de 30; los valores estuvieron aproximadamente entre 1.5 y 3.2, sin evidencia de multicolinealidad local fuerte.

GWR redujo Moran residual a 0.0132 con $p = 0.084$, por lo que no quedó evidencia de dependencia al nivel de 5 %.

MGWR produjo un valor pequeño y negativo de -0.0347 ($p = 0.001$). Esto indica que ambos modelos capturaron casi toda la agrupación positiva inicial; MGWR dejó una alternancia local leve.

El R^2 local de la Fig. 9 varía aproximadamente entre 0.07 y 0.71. Los valores altos indican que habitaciones, dormitorios y baños explican una proporción mayor de la variación del precio en ese entorno. Los valores bajos no significan precios bajos: indican que el modelo explica poco en esa zona y que probablemente faltan variables territoriales o estructurales. El ajuste fue mayor en varios sectores del centro-occidente, centro-oriente y suroriente, y menor en partes de Guayabal y del suroccidente.

III-E. Regímenes por barrio

El modelo de intercepto aleatorio estimó varianza entre barrios de 0.182 y varianza residual de 0.1963. De estas cifras se obtuvo un ICC de 0.4809:

$$ICC = \frac{0.182}{0.182 + 0.1963} = 0.4809.$$

Así, cerca del 48.1 % de la variación restante está entre barrios y el 51.9 % entre viviendas del mismo barrio.

El modelo con intercepto y pendiente aleatoria de baños obtuvo el menor AIC (27 755.80) y RMSE en muestra (0.4303). Mejoró al modelo de solo intercepto (AIC de 28 472.25 y RMSE de 0.4410) y al OLS comparable (RMSE de 0.5773). Esto indica que los barrios difieren tanto en su nivel base de precio como en la relación entre baños y precio.

III-F. Kriging y procesos gaussianos

El variograma esférico fue seleccionado porque produjo el menor RMSE (0.5094), aunque las diferencias frente al exponencial (0.5128) y al gaussiano (0.5153) fueron pequeñas. El modelo estimó nugget de 0.2742, sill total de 1.0484 y range de 12.75 km. El range indica la distancia estimada hasta la cual se mantiene relación espacial; el nugget representa diferencias muy locales o ruido.




Figura 5. Resultados por barrio. Izquierda: precio logarítmico mediano. Derecha: densidad de anuncios por kilómetro cuadrado. Ambos mapas incluyen coordenadas, escala y norte.

Cuadro III
VALIDACIÓN POR BLOQUES DE MODELOS CONTINUOS

Modelo	R^2	MAE	RMSE	Moran
Kriging	0.2256	0.3801	0.5094	0.1878
Reg.-Kriging	0.4373	0.3116	0.4343	0.0657
Proceso gaussiano	0.1610	0.3951	0.5302	0.2481

La semivarianza de la Fig. 11 aumenta con la distancia, lo que indica que viviendas más separadas tienden a diferir más en precio. La estabilización alrededor del sill representa el punto donde aumentar la distancia aporta poca información adicional. El nugget distinto de cero confirma que incluso viviendas muy cercanas pueden presentar diferencias importantes por atributos no observados o ruido del anuncio.

El proceso gaussiano optimizó el kernel

$$0.746^2 \times \text{Matérn}(\ell = [1.05, 0.603], \\ \nu = 1.5) + \text{WhiteKernel}(0.595).$$

La varianza espacial fue aproximadamente 0.557 y el ruido 0.595. El ruido ligeramente mayor muestra que una parte importante de la diferencia entre precios no puede explicarse solo mediante una superficie suave.

Regresión-Kriging fue el mejor método continuo. Su ventaja se debe a que primero explica parte del precio con atributos de la vivienda y luego usa la cercanía para corregir los residuos. Su Moran residual de 0.0657 ($p = 0.017$) fue menor que el de Kriging y el proceso gaussiano, aunque todavía significativo.

La Fig. 12 confirma que regresión-Kriging sigue mejor la diagonal y presenta menor dispersión. Kriging ordinario y el proceso gaussiano tienden a suavizar los extremos: sobreestiman algunos precios bajos y subestiman varios precios altos. Esta pérdida de extremos es esperable cuando la predicción depende principalmente de una superficie espacial suave.

Kriging estimó precios más altos hacia El Poblado y el suroriente y menores hacia el norte. La incertidumbre media fue 0.5989 para Kriging, 0.5628 para regresión-Kriging y 0.6624 para el proceso gaussiano. Una incertidumbre alta no significa un precio alto: significa que el modelo tiene menos evidencia para fijar la predicción, especialmente en zonas periféricas.

La Fig. 14 muestra menor incertidumbre en las zonas centrales con mayor soporte de puntos y valores mayores hacia los bordes oriental y nororiental. Allí el modelo debe extender el patrón aprendido desde observaciones más lejanas. Este resultado ayuda a identificar dónde la superficie debe interpretarse con mayor cautela.

III-G. Comparación final de métodos

La Tabla IV reúne los resultados de la última ejecución. Un R^2 mayor indica mayor proporción explicada, un RMSE menor indica errores más pequeños y un I de Moran residual cercano a cero indica que queda poca estructura espacial sin explicar. El modelo jerárquico no presenta R^2 ni Moran porque esas métricas no se calcularon en su salida final; su comparación se realizó mediante AIC y RMSE.

Las cifras no deben ordenarse como si todos los modelos hubieran usado la misma evaluación. OLS, SEM, SAR-Lag

Cuadro IV
COMPARACIÓN FINAL DE MODELOS SOBRE EL PRECIO LOGARÍTMICO

Modelo	Familia	R^2	RMSE	I de Moran residual
OLS	Dependencia global	0.5828	0.4752	0.1926
SEM	Dependencia global	0.5649	0.4853	0.2437
SAR-Lag	Dependencia global	0.5997	0.4655	0.1753
Random Forest	Aprendizaje automático	0.7756	0.3485	0.0293
XGBoost	Aprendizaje automático	0.5944	0.4686	0.0790
GWR	Heterogeneidad espacial	0.5985	0.4738	0.0132
MGWR	Heterogeneidad espacial	0.6102	0.4678	-0.0347
Intercepto y pendiente aleatoria	Regímenes / multinivel	—	0.4303	—
Kriging ordinario	Campo continuo	0.2256	0.5094	0.1878
Regresión-Kriging	Campo continuo	0.4373	0.4343	0.0657
Proceso gaussiano	Campo continuo	0.1610	0.5302	0.2481




Figura 6. Clusters LISA del precio logarítmico en las viviendas. Solo se clasifican asociaciones locales con $p < 0.05$.




Figura 7. Clusters LISA del precio logarítmico mediano por barrio. Rojo representa Alto-Alto y azul Bajo-Bajo.

y los modelos de aprendizaje automático se evaluaron en la prueba aleatoria original; GWR y MGWR corresponden al ajuste sobre la muestra espacial; el modelo jerárquico muestra ajuste en muestra; y los campos continuos utilizan validación por bloques. Las comparaciones directas se hacen dentro de cada familia. Random Forest fue el mejor en la prueba común; SAR-Lag fue el mejor modelo espacial global; MGWR fue el mejor para representar heterogeneidad; y Regresión-Kriging fue el mejor campo continuo. Los valores residuales de Moran muestran además que una buena predicción no siempre elimina

por completo la dependencia espacial.

IV. DISCUSIÓN

Los resultados responden que la ubicación tiene una relación clara con el precio. El cluster localizado principalmente en El Poblado tuvo una mediana muy superior a los clusters del occidente y del centro-norte. Este resultado no implica que la coordenada cause el precio. La ubicación resume condiciones del barrio y del entorno que no aparecen de forma directa en la base.




Figura 8. Diagnósticos MGWR. Izquierda: número de condición local. Derecha: coeficientes significativos de baños; los puntos grises no fueron significativos.




Figura 9. Capacidad explicativa local de GWR. El color representa el R^2 calculado alrededor de cada punto.

La comparación también muestra que “explicar” y “predecir” no son exactamente el mismo objetivo. Random Forest alcanzó el mayor R^2 de prueba al aprender relaciones no lineales entre ubicación, barrio, tipo de propiedad y atributos físicos. Sin embargo, no permite aislar con la misma claridad el mecanismo

Figura 10. Efectos aleatorios del intercepto por barrio. Los tonos rojos indican un nivel base superior al promedio y los azules uno inferior, después de controlar los atributos incluidos.




Figura 11. Semivarianza experimental y variograma esférico seleccionado.

espacial. SAR-Lag tuvo menor precisión, pero su parámetro espacial positivo permite responder directamente que los precios de viviendas vecinas se relacionan entre sí incluso después de controlar los atributos incluidos.

La cercanía también aporta información. Moran, LISA y SAR muestran que los precios altos se agrupan con otros altos y los bajos con otros bajos. El parámetro de SAR indica una asociación positiva con los precios vecinos. Sin embargo, el Moran residual de prueba muestra que el modelo global no captura toda la estructura.

SEM ofrece una explicación complementaria. Su parámetro elevado y el error filtrado sin dependencia significativa indican que parte de la agrupación corresponde a factores territoriales omitidos. Por ejemplo, viviendas próximas pueden compartir acceso a transporte, seguridad, ruido o calidad urbana. SAR representa la semejanza con el precio vecino; SEM representa condiciones espaciales no observadas. Ambos mecanismos pueden coexistir.

La evidencia también confirma heterogeneidad. MGWR mejoró a GWR y utilizó escalas distintas para cada atributo. El efecto de baños fue positivo en toda la muestra, pero no tuvo la misma intensidad en cada zona. El modelo jerárquico reforzó esta conclusión: casi la mitad de la variación restante estuvo asociada con diferencias entre barrios.

El mapa de R^2 local agrega otra evidencia. La capacidad explicativa cambia dentro de Medellín, de modo que un único resultado global oculta zonas donde los atributos disponibles funcionan bien y otras donde son insuficientes. Esto explica por qué GWR y MGWR mejoran al OLS calculado sobre la misma muestra, pero también por qué ningún modelo local alcanza un ajuste uniforme en toda la ciudad.

La validación por bloques fue más exigente que una partición aleatoria, porque evaluó zonas completas no vistas. Por esta razón, los R^2 de interpolación son menores y no deben compararse directamente con SAR, GWR o MGWR. Regresión-Kriging funcionó mejor porque combinó atributos y dependencia espacial. Kriging y el proceso gaussiano usaron principalmente coordenadas y tuvieron dificultades para representar diferencias propias de cada vivienda.

Las superficies de incertidumbre son importantes para no presentar el mapa como una verdad exacta. El patrón de mayor incertidumbre en la periferia coincide con menor soporte de anuncios y mayor distancia a los datos de entrenamiento. En una aplicación práctica, esas zonas requerirían más información antes de usar la predicción para una decisión concreta.

Predecir el precio es difícil porque faltan variables relevantes: área construida, antigüedad, estado, piso, parqueaderos, seguridad, ruido, accesibilidad y cercanía a servicios. También existe diferencia entre el precio publicado y el precio efectivo de venta. La oferta está concentrada en algunas zonas, mientras en los bordes hay menos anuncios y mayor incertidumbre. Ningún modelo puede recuperar por completo información que no está en los datos.

V. CONCLUSIONES

La ubicación geográfica sí está relacionada con el precio de venta anunciado de la vivienda en Medellín. El suroriente, especialmente El Poblado, concentra precios más altos, mientras varios sectores del centro-norte y norte presentan niveles menores. La ubicación funciona como una síntesis del contexto urbano y barrial, no como una causa aislada del precio.

Existe dependencia espacial porque los precios cercanos tienden a parecerse. Moran global y LISA muestran agrupaciones significativas, y SAR confirma una relación positiva con los precios vecinos. SEM indica además que existen factores territoriales no observados compartidos por viviendas próximas.

También existe heterogeneidad espacial. MGWR mostró que habitaciones, dormitorios y baños actúan a escalas diferentes y que sus coeficientes cambian dentro de la ciudad. Baños presentó la relación local más constante, aunque su intensidad no fue igual en todas las zonas.

Los barrios tienen un papel importante. El ICC de 0.4809 indica que cerca del 48 % de la variación restante corresponde a diferencias entre barrios. Por esto, dos viviendas con atributos semejantes pueden presentar precios distintos según su contexto territorial.

Random Forest fue el mejor predictor general en la prueba común: explicó el 77.6 % de la variación del precio logarítmico y obtuvo RMSE de 0.3485. SAR-Lag fue el modelo espacial global que mejor explicó la relación pedida: obtuvo $R^2 = 0.5997$ y su $\rho = 0.5496$ mostró una asociación positiva con los precios vecinos. Regresión-Kriging fue, de manera separada, el mejor método continuo bajo validación espacial por bloques, con $R^2 = 0.4373$.

No existe un método único para todas las preguntas. Random Forest ofrece la mayor precisión general; SAR-Lag representa mejor y de forma interpretable la dependencia global con los vecinos; SEM identifica factores espaciales omitidos; MGWR describe heterogeneidad; el modelo jerárquico cuantifica diferencias entre barrios; y regresión-Kriging ofrece la mejor superficie evaluada. En conjunto, estos métodos muestran que el precio se relaciona con los atributos de la vivienda, con sus vecinas y con el territorio donde se encuentra.




Figura 12. Predicción frente al valor observado bajo validación por bloques. Una mayor cercanía a la diagonal representa mejor correspondencia entre predicción y observación.




Figura 13. Predicción de Kriging ordinario. Los precios esperados son mayores hacia El Poblado y el suroriente y menores hacia el norte.

REFERENCIAS

- [1] E. V. Aristizábal Giraldo, “Materiales del curso Análisis Geoespacial,” Universidad Nacional de Colombia. [En línea]. Disponible en: <https://edieraristizabal.github.io/AnalisisGeoespacial/>
- [2] E. V. Aristizábal Giraldo, *Libro de Análisis Geoespacial*. [En línea]. Disponible en: https://edieraristizabal.github.io/Libro_AnalisisGeoespacial/intro.html
- [3] J. Usuga Ortiz, “Colombia Housing Properties Price,” Kaggle. [En línea]. Disponible en: <https://www.kaggle.com/datasets/julianusugaortiz/colombia-housing-properties-price>
- [4] K. A. Parra Henao, “3008338 Geospatial Analysis,” GitHub. [En línea]. Disponible en: <https://github.com/evinracher/3008338-geospatial-analysis>




Figura 14. Desviación estándar posterior del proceso gaussiano. Los valores altos representan mayor incertidumbre, no precios más altos.