

Dependencia y heterogeneidad espacial del precio de la vivienda en Medellín

Kevin Arley Parra Henao
Universidad Nacional de Colombia, sede Medellín
Curso de Análisis Geoespacial

Resumen—Este trabajo analiza cómo la ubicación y la cercanía entre viviendas se relacionan con el precio de venta en Medellín. Los anuncios se representan como puntos marcados, donde la marca principal es el logaritmo natural del precio. El análisis combina centrografía, densidad kernel normalizada, K-means espacial, Moran global y local, modelos OLS, SEM y SAR, regresión geográficamente ponderada (GWR y MGWR), modelos jerárquicos por barrio, Kriging ordinario, regresión-Kriging y procesos gaussianos. El precio logarítmico presentó dependencia espacial positiva y significativa (I de Moran de 0.5898 con diez vecinos, $p = 0.001$). SAR confirmó una relación positiva con los precios vecinos ($\rho = 0.5496$), mientras SEM encontró dependencia en factores territoriales no observados ($\lambda = 0.7351$). MGWR mostró que la relación entre los atributos y el precio cambia dentro de la ciudad. El modelo jerárquico estimó que el 48.1 % de la variación restante se relaciona con diferencias entre barrios. En validación por bloques, regresión-Kriging fue el mejor método de interpolación ($R^2 = 0.4373$ y RMSE de 0.4343). Los resultados muestran que la ubicación influye mediante el contexto barrial, la semejanza entre precios cercanos y relaciones que cambian entre zonas.

Index Terms—precio de vivienda, dependencia espacial, heterogeneidad espacial, MGWR, modelos jerárquicos, Kriging, procesos gaussianos.

I. INTRODUCCIÓN

El precio de una vivienda no depende únicamente de sus habitaciones, dormitorios o baños. Dos inmuebles con características parecidas pueden tener precios diferentes por estar ubicados en barrios distintos. La accesibilidad, la seguridad, los servicios cercanos, la calidad del entorno y la valoración histórica de cada sector forman parte de esa diferencia. Además, los anuncios próximos suelen compartir condiciones de mercado y, por tanto, sus precios pueden parecerse.

Este comportamiento plantea dos conceptos principales. La *dependencia espacial* aparece cuando el precio de una vivienda se relaciona con los precios de las viviendas cercanas. La *heterogeneidad espacial* ocurre cuando una misma característica no tiene la misma relación con el precio en toda la ciudad. Por ejemplo, un baño adicional puede estar asociado con un cambio mayor de precio en una zona que en otra.

Los materiales del curso presentan herramientas para estudiar estas dos dimensiones, desde patrones de puntos y autocorrelación hasta modelos locales, jerárquicos y procesos gaussianos [1], [2]. Siguiendo ese enfoque, este proyecto responde dos preguntas: ¿cómo se relaciona la ubicación geográfica de una vivienda en Medellín con su precio?, y ¿cómo la ubicación y

la cercanía de inmuebles vecinos ayudan a explicar y predecir su precio de venta?

El objetivo es describir el patrón territorial del precio, medir su dependencia espacial, evaluar si las relaciones cambian entre zonas y comparar métodos de predicción espacial. No se busca establecer causalidad. Los resultados indican asociaciones: muestran dónde aparecen los patrones y cuánto ayudan a explicar o predecir el precio.

II. DATOS Y METODOLOGÍA

II-A. Datos y representación espacial

Se utilizó el conjunto *Colombia Housing Properties Price*. Después del tratamiento realizado previamente en el proyecto, quedaron 35 814 anuncios de Medellín. La partición original contiene 25 069 observaciones de entrenamiento y 10 745 de prueba. Esta etapa espacial no modificó la limpieza ni los modelos de aprendizaje automático ya existentes.

Las variables empleadas incluyen precio, longitud, latitud, barrio, tipo de propiedad, habitaciones, dormitorios y baños. Debido a la asimetría del precio se utilizó:

$$y_i = \log(\text{precio}_i).$$

El logaritmo reduce el efecto de valores extremos y facilita la comparación de cambios relativos. Esta transformación y su uso en el análisis de precios espaciales siguen el tratamiento presentado en el material del curso [1].

Los anuncios se convirtieron en puntos y se proyectaron en MAGNA-SIRGAS / Origen-Nacional (EPSG:9377), cuyas unidades son metros. La unión espacial con 252 polígonos oficiales del material del curso asignó 22 857 puntos de entrenamiento a 226 barrios con al menos un anuncio. GWR, MGWR y los procesos continuos utilizaron únicamente geometrías dentro del límite de Medellín.

II-B. Patrón de puntos y agrupamiento

Cada anuncio se trató como un punto con una marca de precio. Se calcularon el centro medio, el centro ponderado por `log_price`, una elipse de desviación estándar y la envolvente convexa. La superficie kernel normalizada se definió como:

$$\hat{m}(s) = \frac{\sum_i K_h(s - s_i) y_i}{\sum_i K_h(s - s_i)},$$

con ancho de banda de 1 km. La normalización evita confundir una zona con muchos anuncios con una zona de precios altos.

La formulación del suavizado kernel se basa en el capítulo de patrones de puntos del libro del curso [2].

K-means se ajustó solamente con coordenadas proyectadas y estandarizadas. Se probaron entre dos y seis grupos. Silhouette mide qué tan compactos y separados están los grupos, mientras el método del codo identifica cuándo aumentar el número de clusters deja de reducir de manera importante la inercia.

II-C. Dependencia espacial

Para los puntos se construyeron matrices de los vecinos más cercanos (KNN) con 5, 10 y 20 vecinos. Moran global mide si los valores cercanos tienden a parecerse. Un valor positivo y significativo indica agrupación de valores similares. Moran local o LISA identifica dónde ocurre el patrón:

- Alto–Alto: precio alto rodeado por precios altos.
- Bajo–Bajo: precio bajo rodeado por precios bajos.
- Alto–Bajo y Bajo–Alto: observaciones que contrastan con su entorno.

Para los barrios se utilizó una matriz Queen: dos barrios son vecinos si comparten un borde o un vértice. Se calcularon Moran y LISA sobre la mediana barrial de `log_price`, usando 999 permutaciones.

OLS se empleó como modelo global de referencia:

$$\mathbf{y} = \mathbf{X}\beta + \varepsilon.$$

La notación de OLS y de los modelos espaciales siguientes se basa en los contenidos de correlación y regresión espacial del libro y del material del curso [2], [1]. Luego se ajustaron SEM y SAR. SEM representa dependencia en factores espaciales no incluidos:

$$\mathbf{u} = \lambda \mathbf{W}\mathbf{u} + \varepsilon.$$

SAR incorpora el precio de las viviendas vecinas:

$$\mathbf{y} = \rho \mathbf{W}\mathbf{y} + \mathbf{X}\beta + \varepsilon.$$

II-D. Heterogeneidad y regímenes espaciales

GWR (*Geographically Weighted Regression*) estima coeficientes alrededor de cada punto y usa un ancho de banda común. MGWR (*Multiscale Geographically Weighted Regression*) permite un ancho diferente para cada variable:

$$y_i = \beta_0(s_i) + \sum_{k=1}^p \beta_k(s_i)x_{ik} + \varepsilon_i.$$

Esta formulación corresponde al desarrollo de GWR y MGWR presentado en el libro del curso [2].

Se seleccionaron 1 890 puntos distribuidos dentro de Medellín. Los predictores fueron habitaciones, dormitorios y baños estandarizados. El ancho se seleccionó mediante AICc, que compara ajuste y complejidad y penaliza parámetros innecesarios. También se evaluaron significancia local, número de condición y Moran residual.

Para representar barrios como regímenes se compararon OLS, un *Random Intercept Model* y un modelo con intercepto y pendiente aleatoria de baños. El ICC se calculó como:

$$\text{ICC} = \frac{\sigma_{\text{barrio}}^2}{\sigma_{\text{barrio}}^2 + \sigma_{\text{residual}}^2}.$$

Este valor indica qué parte de la variación restante corresponde a diferencias entre barrios. La definición del ICC y la estructura jerárquica siguen el capítulo de modelos jerárquicos del libro [2].

II-E. Interpolación y validación espacial

Se construyeron 38 bloques espaciales de aproximadamente 2 km: 1 646 puntos quedaron para entrenamiento y 244 para prueba. Ningún bloque de prueba apareció en entrenamiento, por lo que la evaluación representa la predicción de zonas completas no observadas.

Kriging ordinario predice mediante valores cercanos y un variograma. Se compararon modelos esférico, exponencial y gaussiano, con un máximo de 80 vecinos. Regresión-Kriging primero estimó la tendencia con habitaciones, dormitorios y baños mediante Ridge y después interpoló los residuos.

El proceso gaussiano utilizó un kernel Matérn con ruido blanco:

$$k(s_i, s_j) = \sigma_f^2 k_{\text{Matérn } 3/2}(s_i, s_j) + \sigma_n^2 \delta_{ij}.$$

La representación mediante funciones de covarianza y ruido se basa en los capítulos de Kriging y procesos gaussianos del libro y en el material del curso [2], [1]. La media posterior es la predicción y la desviación estándar posterior mide incertidumbre. Los métodos se compararon con R^2 , MAE, RMSE y Moran residual.

III. RESULTADOS

III-A. Patrón espacial y barrios

El centro medio se ubicó en Tenche y el centro ponderado por precio en Trinidad. La distancia entre ambos fue de 65.02 m. El pequeño desplazamiento indica que los anuncios costosos del suroriente no cambian mucho el centro general, porque la oferta también se distribuye por el centro, occidente y norte. La elipse presentó semiejes de 3.38 km y 1.81 km, con orientación de 105.33 grados, coherente con la forma alargada del valle.

La superficie kernel varió aproximadamente entre 19.00 y 20.64 en escala logarítmica, equivalentes a valores cercanos a 178 y 922 millones de pesos. Sus máximos se concentran hacia El Poblado y representan promedios locales altos, no solo mayor cantidad de anuncios.

K-means seleccionó tres clusters con Silhouette de 0.520. El cluster 0 agrupó principalmente sectores centrales y del norte, como La Candelaria y Boston, con mediana de 250 millones. El cluster 1 cubrió buena parte del occidente, incluidos Laureles, Los Conquistadores y Belén, con 340 millones. El cluster 2 reunió principalmente El Poblado, con barrios como El Tesoro, San Lucas, Los Balsos y Castropol, y alcanzó 690 millones. El precio no definió los grupos; las diferencias aparecieron después de agrupar solamente por ubicación.

III-B. Dependencia espacial global y local

Sí existe dependencia espacial. Con diez vecinos, Moran de `log_price` fue 0.5898 ($p = 0.001$). El resultado es positivo y significativo: las viviendas cercanas tienden a presentar precios similares y el patrón no se explica por azar. El valor disminuyó




Figura 1. Centrografía del patrón de anuncios. La cruz es el centro medio, la estrella es el centro ponderado por precio, la elipse resume dispersión y la línea roja muestra la envolvente convexa.

de 0.6254 con cinco vecinos a 0.5553 con veinte, pero la conclusión se mantuvo.

LISA puntual clasificó 23.81 % de las viviendas como Alto-Alto y 24.44 % como Bajo-Bajo. Los casos Bajo-Alto representaron 3.23 % y los Alto-Bajo 2.09 %. A escala barrial, Moran fue 0.4752 ($p = 0.001$). Se identificaron 29 barrios Alto-Alto, con mediana conjunta de 690 millones, y 37 Bajo-Bajo, con mediana de 165 millones.

La matriz Queen tuvo 4.86 vecinos por barrio, dos componentes conectados y ninguna isla. El componente principal incluyó 224 barrios; el segundo estuvo formado por María Cano-Carambolas y Carpinelo, conectados entre sí pero no con los barrios observados del componente principal.

III-C. Modelos globales de dependencia

OLS obtuvo $R^2 = 0.5870$ y RMSE de 0.4745 en entrenamiento. Sin embargo, sus residuos conservaron Moran de 0.2461 ($p = 0.001$). Por tanto, los atributos incluidos no explicaron toda la estructura territorial.

SEM estimó $\lambda = 0.7351$ ($p < 0.001$). El valor alto indica que factores territoriales no incluidos comparten un patrón entre viviendas vecinas. Después de filtrar esa estructura, el error presentó Moran de -0.0013 y $p = 0.243$, sin evidencia de dependencia restante.




Figura 2. Clusters LISA del precio logarítmico mediano por barrio. Rojo representa Alto-Alto y azul Bajo-Bajo.

Cuadro I
MODELOS ESPACIALES GLOBALES EN PRUEBA

Modelo	R^2	RMSE	Moran residual
OLS	0.5828	0.4752	0.1926
SEM	0.5649	0.4853	0.2437
SAR	0.5997	0.4655	0.1753

Cuadro II
COMPARACIÓN DE HETEROGENEIDAD SOBRE 1 890 PUNTOS

Modelo	R^2 aj.	AICc	RMSE	Moran
OLS	0.3758	—	0.6129	0.2722
GWR	0.5985	2837.88	0.4738	0.0132
MGWR	0.6102	2773.17	0.4678	-0.0347

SAR estimó $\rho = 0.5496$ ($p < 0.001$). Esto significa que el precio vecino aporta información positiva al explicar el precio de una vivienda. En prueba, SAR fue el mejor modelo espacial global, con $R^2 = 0.5997$ y RMSE de 0.4655. Su Moran residual fue 0.1753, por lo que todavía quedó estructura sin explicar.

III-D. Heterogeneidad espacial

MGWR obtuvo el mejor equilibrio entre ajuste y complejidad. Sus anchos de banda fueron 64 vecinos para el intercepto, 1 015 para habitaciones, 364 para dormitorios y 149 para baños. El

ancho grande de habitaciones indica una relación amplia y estable; los anchos menores del intercepto y baños permiten cambios más locales.

Baños fue positivo y significativo en 83.54 % de los puntos, habitaciones en 54.07 % y dormitorios en 5.03 %. El coeficiente local de baños varió aproximadamente entre 0.154 y 0.747. Por tanto, sí hay heterogeneidad: la relación es positiva, pero su intensidad cambia según la zona. Ningún punto superó el número de condición de 30; los valores estuvieron aproximadamente entre 1.5 y 3.2, sin evidencia de multicolinealidad local fuerte.

GWR redujo Moran residual a 0.0132 con $p = 0.084$, por lo que no quedó evidencia de dependencia al nivel de 5 %. MGWR produjo un valor pequeño y negativo de -0.0347 ($p = 0.001$). Esto indica que ambos modelos captaron casi toda la agrupación positiva inicial; MGWR dejó una alternancia local leve.

III-E. Regímenes por barrio

El modelo de intercepto aleatorio estimó varianza entre barrios de 0.182 y varianza residual de 0.1963. De estas cifras se obtuvo un ICC de 0.4809:

$$\text{ICC} = \frac{0.182}{0.182 + 0.1963} = 0.4809.$$

Así, cerca del 48.1 % de la variación restante está entre barrios y el 51.9 % entre viviendas del mismo barrio.

El modelo con intercepto y pendiente aleatoria de baños obtuvo el menor AIC (27 755.80) y RMSE en muestra (0.4303). Mejoró al modelo de solo intercepto (AIC de 28 472.25 y RMSE de 0.4410) y al OLS comparable (RMSE de 0.5773). Esto indica que los barrios difieren tanto en su nivel base de precio como en la relación entre baños y precio.

III-F. Kriging y procesos gaussianos

El variograma esférico fue seleccionado porque produjo el menor RMSE (0.5094), aunque las diferencias frente al exponencial (0.5128) y al gaussiano (0.5153) fueron pequeñas. El modelo estimó nugget de 0.2742, sill total de 1.0484 y range de 12.75 km. El range indica la distancia estimada hasta la cual se mantiene relación espacial; el nugget representa diferencias muy locales o ruido.

El proceso gaussiano optimizó el kernel

$$0.746^2 \times \text{Matérn}(\ell = [1.05, 0.603], \nu = 1.5) + \text{WhiteKernel}(0.595).$$

La varianza espacial fue aproximadamente 0.557 y el ruido 0.595. El ruido ligeramente mayor muestra que una parte importante de la diferencia entre precios no puede explicarse solo mediante una superficie suave.

Regresión-Kriging fue el mejor método continuo. Su ventaja se debe a que primero explica parte del precio con atributos de la vivienda y luego usa la cercanía para corregir los residuos. Su Moran residual de 0.0657 ($p = 0.017$) fue menor que el de Kriging y el proceso gaussiano, aunque todavía significativo.

Cuadro III
VALIDACIÓN POR BLOQUES DE MODELOS CONTINUOS

Modelo	R^2	MAE	RMSE	Moran
Kriging	0.2256	0.3801	0.5094	0.1878
Reg.-Kriging	0.4373	0.3116	0.4343	0.0657
Proceso gaussiano	0.1610	0.3951	0.5302	0.2481

Kriging estimó precios más altos hacia El Poblado y el suroriente y menores hacia el norte. La incertidumbre media fue 0.5989 para Kriging, 0.5628 para regresión-Kriging y 0.6624 para el proceso gaussiano. Una incertidumbre alta no significa un precio alto: significa que el modelo tiene menos evidencia para fijar la predicción, especialmente en zonas periféricas.




Figura 3. Diagnósticos MGWR. Izquierda: número de condición local. Derecha: coeficientes significativos de baños; los puntos grises no fueron significativos.




Figura 4. Efectos aleatorios del intercepto por barrio. Los tonos rojos indican un nivel base superior al promedio y los azules uno inferior, después de controlar los atributos incluidos.

Figura 5. Predicción de Kriging ordinario. Los precios esperados son mayores hacia El Poblado y el suroriente y menores hacia el norte.

IV. DISCUSIÓN

Los resultados responden que la ubicación tiene una relación clara con el precio. El cluster localizado principalmente en El Poblado tuvo una mediana muy superior a los clusters del occidente y del centro-norte. Este resultado no implica que la coordenada cause el precio. La ubicación resume condiciones del barrio y del entorno que no aparecen de forma directa en la base.

La cercanía también aporta información. Moran, LISA y SAR muestran que los precios altos se agrupan con otros altos y los bajos con otros bajos. El parámetro de SAR indica una asociación positiva con los precios vecinos. Sin embargo, el Moran residual de prueba muestra que el modelo global no captura toda la estructura.

SEM ofrece una explicación complementaria. Su parámetro elevado y el error filtrado sin dependencia significativa indican que parte de la agrupación corresponde a factores territoriales omitidos. Por ejemplo, viviendas próximas pueden compartir acceso a transporte, seguridad, ruido o calidad urbana. SAR representa la semejanza con el precio vecino; SEM representa condiciones espaciales no observadas. Ambos mecanismos pueden coexistir.

La evidencia también confirma heterogeneidad. MGWR mejoró a GWR y utilizó escalas distintas para cada atributo. El efecto de baños fue positivo en toda la muestra, pero no tuvo la misma intensidad en cada zona. El modelo jerárquico reforzó esta conclusión: casi la mitad de la variación restante estuvo asociada con diferencias entre barrios.

La validación por bloques fue más exigente que una partición aleatoria, porque evaluó zonas completas no vistas. Por esta razón, los R^2 de interpolación son menores y no deben compararse directamente con SAR, GWR o MGWR.

Regresión-Kriging funcionó mejor porque combinó atributos y dependencia espacial. Kriging y el proceso gaussiano usaron principalmente coordenadas y tuvieron dificultades para representar diferencias propias de cada vivienda.

Predecir el precio es difícil porque faltan variables relevantes: área construida, antigüedad, estado, piso, parqueaderos, seguridad, ruido, accesibilidad y cercanía a servicios. También existe diferencia entre el precio publicado y el precio efectivo de venta. La oferta está concentrada en algunas zonas, mientras en los bordes hay menos anuncios y mayor incertidumbre. Ningún modelo puede recuperar por completo información que no está en los datos.

V. CONCLUSIONES

La ubicación geográfica está relacionada con el precio de la vivienda en Medellín. El suroriente, especialmente El Poblado, concentra precios más altos, mientras varios sectores del centro-norte y norte presentan niveles menores. La ubicación funciona como una síntesis del contexto urbano y barrial.

Existe dependencia espacial porque los precios cercanos tienden a parecerse. Moran global y LISA muestran agrupaciones significativas, y SAR confirma una relación positiva con los precios vecinos. SEM indica además que existen factores territoriales no observados compartidos por viviendas próximas.

También existe heterogeneidad espacial. MGWR mostró que habitaciones, dormitorios y baños actúan a escalas diferentes y que sus coeficientes cambian dentro de la ciudad. Baños presentó la relación local más constante, aunque su intensidad no fue igual en todas las zonas.

Los barrios tienen un papel importante. El ICC de 0.4809 indica que cerca del 48 % de la variación restante corresponde a diferencias entre barrios. Por esto, dos viviendas con atributos semejantes pueden presentar precios distintos según su contexto territorial.

Regresión-Kriging fue el mejor método continuo bajo validación espacial, pero explicó el 43.7 % de la variación en bloques no observados. Su resultado confirma que combinar atributos y cercanía es mejor que interpolar únicamente con coordenadas, aunque todavía queda dependencia residual.

No existe un método único para todas las preguntas. SAR representa mejor la dependencia global con los vecinos; SEM identifica factores espaciales omitidos; MGWR describe heterogeneidad; el modelo jerárquico cuantifica diferencias entre barrios; y regresión-Kriging ofrece la mejor superficie evaluada. En conjunto, estos métodos muestran que el precio depende de la vivienda, de sus vecinos y del territorio donde se encuentra.

REFERENCIAS

- [1] E. V. Aristizábal Giraldo, "Materiales del curso Análisis Geoespacial," Universidad Nacional de Colombia. [En línea]. Disponible en: <https://edieraristizabal.github.io/AnalisisGeoespacial/>
- [2] E. V. Aristizábal Giraldo, *Libro de Análisis Geoespacial*. [En línea]. Disponible en: https://edieraristizabal.github.io/Libro_AnalisisGeoespacial/intro.html